



重庆工商大学学报(自然科学版)

Journal of Chongqing Technology and Business University(Natural Science Edition)

ISSN 1672-058X,CN 50-1155/N

《重庆工商大学学报(自然科学版)》网络首发论文

题目：复杂动态环境下基于 Q-learning 的机器人路径规划研究
作者：黄子航，杨超宇，冉艳霞
收稿日期：2026-01-05
网络首发日期：2026-03-13
引用格式：黄子航，杨超宇，冉艳霞. 复杂动态环境下基于 Q-learning 的机器人路径规划研究[J/OL]. 重庆工商大学学报(自然科学版).
<https://link.cnki.net/urlid/50.1155.N.20260313.0916.002>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

复杂动态环境下基于 Q-learning 的机器人路径规划研究

黄子航, 杨超宇, 冉艳霞

安徽理工大学 计算机科学与工程学院, 安徽 淮南 232001

摘要:【目的】针对移动机器人在复杂动态环境下路径规划适应性不足的问题, 传统 A*等启发式算法虽能在静态场景中实现路径最优, 但在处理动态障碍物时缺乏实时调整能力, 导致规划失败。研究旨在开发具备自主学习和动态适应能力的智能路径规划方法。【方法】提出一种基于 Q-learning 的无模型强化学习导航方法, 利用贝尔曼方程构建智能体决策机制, 通过状态-行动-奖励的持续交互实现策略自主进化。采用 ϵ -贪心策略平衡探索与利用, 设置学习率 $\alpha=0.1$ 、折扣因子 $\gamma=0.9$ 。在 20×20 网格化仿真环境中构建静态和动态障碍场景, 系统对比 Q-learning 与 A*算法的性能, 通过 50 次迭代训练验证算法收敛性。【结果】在静态环境下, A*算法在路径长度(29 步)和搜索时间(7.8 s)上优于 Q-learning 算法(34 步, 12.1 s), 路径缩短 17.2%, 效率提升 35.5%。在动态障碍场景中, Q-learning 算法通过自适应更新 Q 表, 在 12 次迭代内收敛至稳定策略, 避障成功率达 100%, 而 A*算法规划成功率仅 62.3%。路径迭代分析显示, Q-learning 在前 30 次迭代中波动较大($\sigma=8.7$ 步), 但在第 34 次迭代后稳定在 34 步。【结论】Q-learning 算法为移动机器人在高不确定性、频繁变化的复杂动态场景下提供了强自适应性的路径规划框架。相比传统算法, 强化学习方法通过持续交互实现策略进化, 显著提升动态避障能力和系统鲁棒性, 对军事侦察、灾害救援、仓储物流等场景的自主导航具有重要指导意义。未来可结合深度神经网络和多智能体协同机制应对更复杂环境挑战。

关键词: 机器人路径规划; Q-learning; A*算法; 强化学习; 动态环境

中图分类号: TP391.9

文献标识码: A

Research on Robot Path Planning Based on Q-learning in Complex Dynamic Environments

Huang Zihang, Yang Chaoyu, Ran Yanxia

Anhui University of Science and Technology, Huainan 232001, Anhui, China

Abstract: To address the insufficient adaptability of mobile robot path planning in complex dynamic environments. Traditional heuristic algorithms such as A* can achieve optimal paths in static scenarios. However, they lack real-time adjustment capabilities when dealing with dynamic obstacles. This leads to planning failures. This research aims to develop an intelligent path planning method with autonomous learning and dynamic adaptation capabilities. **Methods:** A model-free reinforcement learning navigation method based on Q-learning was proposed. This method constructs an agent decision-making mechanism using the Bellman equation. It achieves autonomous policy evolution through continuous state-action-reward interactions. An ϵ -greedy strategy was employed to balance exploration and exploitation. The learning rate was set to $\alpha=0.1$ and the discount factor to $\gamma=0.9$. Both static and dynamic obstacle scenarios were constructed in a 20×20 grid-based simulation environment. The performance of Q-learning and A* algorithms was systematically compared. Convergence was validated through 50 iterations of training. **Results:** In static environments, the A* algorithm outperforms Q-learning in both path length and search time. A* achieves 29 grid units path length compared to Q-learning's 34 grid units. A* requires 7.8 s search time while Q-learning needs 12.1 s. This represents 17.2% shorter paths and 35.5% higher efficiency for A*. In dynamic obstacle scenarios, Q-learning shows significant advantages. It converges to a stable policy within 12 iterations through adaptive Q-table updates. Q-learning achieves 100% obstacle avoidance success rate. In contrast, A* achieves only 62.3% planning success rate. Path iteration analysis shows that Q-learning experiences large fluctuations in the first 30 iterations ($\sigma=8.7$ grid units). However, it stabilizes at 34 grid units after the 34th iteration. **Conclusion:** The Q-learning algorithm provides a highly adaptive path planning framework for mobile robots. It is particularly suitable for complex dynamic

收稿日期: 2026-01-05; 修回日期: 2026-03-12。

作者简介: 黄子航(1997—), 男, 安徽淮南人, 硕士, 从事深度学习研究。

通信作者: 杨超宇(1981—), 男, 安徽淮南人, 教授, 博士, 从事计算机视觉研究.Email: yangchy@aust.edu.cn.

scenarios with high uncertainty and frequent changes. Compared to traditional algorithms, reinforcement learning achieves policy evolution through continuous interaction. This significantly enhances dynamic obstacle avoidance capability and system robustness. The research has important guiding significance for autonomous navigation in military reconnaissance, disaster rescue, and warehouse logistics. Future research can integrate deep neural networks to optimize state space representation. Multi-agent collaboration mechanisms can be introduced to address more complex environmental challenges.

Keywords: robot path planning; Q-learning; A* algorithm; reinforcement learning; dynamic environments

随着移动机器人技术的飞速发展,在复杂的动态环境中进行可靠的路径规划,已成为智能机器人导航领域的核心挑战。在许多复杂场景中,如排雷、侦察、运送物资等任务,准确可靠的路径规划是移动机器人顺利完成的核心能力之一^[1-2]。路径规划的目标是在满足安全性约束的前提下,以最优方式生成从起点到目标点的可行路径,最大程度地避免移动机器人运动过程中可能发生的碰撞事故。完善的路径规划技术不仅能显著提高机器人的工作效率和任务完成质量,更能有效规避实际应用中的各类风险,对推动机器人技术的实用化具有重要意义。

近年来,强化学习作为一种无模型的智能决策方法,在机器人路径规划领域展现出巨大潜力^[3-6]。其中,Q-learning算法作为强化学习的经典代表,通过智能体与环境的持续交互实现策略优化,无需预先建立环境模型,特别适用于动态未知环境下的路径规划问题^[7-10]。在策略学习方面,强化学习可分为on-policy和off-policy两类方法。on-policy方法在策略执行过程中同步进行策略评估和改进,虽然计算效率较高,但容易陷入局部最优。而off-policy方法通过分离行为策略与目标策略,利用行为策略收集的经验数据离线优化目标策略,能够获得全局最优解,Q-learning正是off-policy方法的典型代表^[4-6]。

Q-learning算法在多个领域的路径规划应用中取得了显著成果。在单机机器人系统中,Abdi等^[11]将Q-learning与神经网络结合,为机械臂提供了混合路径规划方法;Alhassow等^[12]基于Voronoi图和Q-learning设计了类车机器人的路径规划算法。在多机器人系统中,Yang等^[13]采用深度Q网络(DQN)实现了无人仓库中的多机器人协同路径规划;Diao等^[14]将模糊Q-learning应用于无人飞行器的欠驱动系统控制。近期研究进一步拓展了Q-learning的应用范围,Gharbi^[7]提出了动态奖励增强的Q-learning方法,显著提升了动态障碍避障性能;Montero等^[8]针对部分可观测环境提出了

记忆驱动的深度强化学习导航方法;Raj和Kos^[9]系统研究了强化学习技术在未知复杂环境中的机器人导航问题;Wang等^[10]基于改进的双深度Q网络算法实现了高效的路径规划;Sachan和Pathak^[15]重点解决了全向轮移动机器人在动态障碍环境下的安全导航问题。

与此同时,传统的全局路径规划算法如A*算法、Dijkstra算法、遗传算法等也在不断改进。A*算法通过引入启发函数优化Dijkstra算法,能够高效搜索静态已知环境中的最优路径^[16-18,19-20]。王中玉等^[16]提出了改进的A*算法优化路径长度和转折角度,但仍存在冗余节点问题;Das等^[17]设计了实时A*算法应用于网格地图环境,虽然提高了在线规划能力,但路径长度有待优化;Duchon等^[18]通过引入Basic、Theta*和Phi*参数改进了算法性能,但应用场景相对局限。最新研究中,Li等^[19]设计了适应多环境的A*算法,通过自适应启发函数和跳点优化提升了规划效率;Kabir等^[20]针对机器人运动块优化了A*算法的评估函数,大幅提高了搜索性能。

然而,已有研究也暴露出一些共性问题。首先,传统启发式算法虽然在静态已知环境中表现优异,但面对动态障碍物和未知环境时适应性严重不足,难以实时调整路径规划策略^[16-18]。其次,现有Q-learning方法在复杂动态环境下的收敛速度较慢,难以满足实时性要求^[7-10]。第三,多数研究聚焦于单一算法的局部改进,缺乏对不同算法在静态与动态环境下的系统性对比分析。第四,在奖励函数设计和探索-利用策略平衡方面仍存在优化空间^[7,9]。这些不足限制了路径规划算法在复杂实际场景中的广泛应用。

针对上述问题,本文提出以下研究思路:

(1) 系统对比分析。本研究通过构建统一的20×20网格化仿真环境,系统对比A*算法与Q-learning算法在静态已知环境和动态未知环境下的性能表现,揭示两类算法的适用场景和优劣特性。

(2) 算法优化设计。针对Q-learning算法在复杂环境下收敛慢的问题,本文采用 ϵ -贪心策略平衡探索与利用,通过优化学习率和折扣因子设计,加速算法收敛并提升路径质量。

(3) 动态环境验证。重点验证Q-learning算法在包含突发动态障碍物的未知场景中的自适应能力,通过Q表实时更新机制实现快速策略修正。

本文的主要创新点在于:首次在相同实验条件下系统对比了传统启发式算法与强化学习算法在不同环境类型下的性能差异,为算法选择提供了明确的实验依据。针对动态环境路径规划问题,提出了基于自适应Q表更新的策略优化方法,显著提升了Q-learning算法在突发障碍场景下的鲁棒性。通过大量实验验证了Q-learning算法在不确定性高、环境变化频繁的复杂场景下相比传统算法的显著优势,为智能机器人在动态环境下的自主导航提供了理论支撑和实践指导。

1 路径规划算法原理

机器人的路径规划问题是指根据某种或某些优化准则(如最小工作成本、最短行走路径、最短行走时间等),找到一条从机器人初始状态到目标状态的最优路径,以避免工作空间中的障碍物。本文将设置一个简单的迷宫环境,紫色位置代表终点、黑色位置代表障碍物,黄色位置代表起点,让绿色块通过不断探索和学习慢慢走到紫色位置,如图 1 所示,目标是找到一种算法,以更高的效率获得通往终点的最佳路径。




图 1 路径规划图

Fig.1 Route Planner

1.1 广度优先搜索和深度优先搜索

路径规划的最基本原则是广度优先搜索(Breadth First Search, BFS)和深度优先搜索(Depth-First-Search, DFS)。BFS 以起点“A”为

圆心,先搜索 A 周围的所有点,形成类似圆的“A”点搜索区域,然后扩大搜索半径,获得更大的搜索区域,直到在搜索区域内找到终点“B”点。BFS 保证了从起点到终点的最小成本,即无论搜索过程是否涉及多个网格,都能获得最短路径,因此这种方法除非能获得最佳路径,否则空间复杂度较高,其伪代码如表 1 所示。

表 1 BFS 算法的伪代码

Table 1 Pseudo-code for the BFS algorithm

算法 1: BFS 算法
(1) 初始化: 创建一个队列 Q 创建一个集合 visited 用来存储访问过的节点 将起点 A 加入队列 Q 将起点 A 标记为已访问
(2) 如果队列 Q 不为空,则执行以下步骤: a. 从 Q 中取出一个节点 current b. 如果 current 是终点 B,则结束搜索,返回成功 c. 否则,对于 current 节点的每一个相邻节点 n: i. 如果 n 未被访问过: - 将 n 加入队列 Q - 标记 n 为已访问 - 记录 n 的前驱节点为 current(用于重建路径)
(3) 如果队列 Q 为空,返回失败(未找到路径)

DFS 以“A”为起点,向终点“B”的方向搜索。DFS 是在离 A 尽可能远、离 B 尽可能近的地方搜索,通过不断修正行进方向与目标方向的偏差,有效缩小了搜索范围。然而,受限于深度优先策略的局部性,该方法往往无法保证获得全局最优路径,其伪代码如表 2 所示。

表 2 DFS 算法的伪代码

Table 2 Pseudo-code for the DFS algorithm

算法 2: DFS 算法
(1) 初始化: 创建一个栈 stack 将起点 A 压入栈中 创建一个集合 visited 用来存储访问过的节点
(2) 如果栈不为空,则执行以下步骤: a. 弹出栈顶元素,设为当前节点 current b. 如果 current 是终点 B: i. 输出或记录路径 ii. 结束搜索 c. 如果 current 尚未被访问: i. 标记 current 为已访问

ii. 对于 current 的每一个未访问的邻接节点 n, 按照离终点 B 近远程度的优先级:

- 将 n 压入栈中

(3) 如果栈为空, 返回未找到路径

1.2 A*算法

结合 BFS 和 DFS 得到一种新算法, 即 A*。A*考虑了从起点经过当前路线的成本, 并不断计算当前路线方向是否更接近终点方向。A*公式为

$$F(x) = G(x) + H(x) \quad (1)$$

式(1)中, $F(x)$ 是节点 x 的综合优先级, 本文将使用最小的优先级。 $G(x)$ 是节点 x 与起点之间距离的成本, $H(x)$ 是节点 x 到终点的估计成本。然后每移动一个点就重新确认一次方向, 直到到达终点。在不考虑前往不同点有不同成本的情况下, 如点与点之间代价权重相同, A*是找到路径的最有效方法, 其伪代码如表 3 所示。

表 3 A*算法的伪代码

Table 3 Pseudo-code for the A* algorithm

算法 3: A*算法

输入: 起点 S, 终点 T

输出: 从 S 到 T 的最优路径

- (1) 计算起点 S 到终点 T 的估计代价, 并赋值给 $h(S)$
- (2) 初始化 $g(S)=0$, $f(S)=g(S)+h(S)$
- (3) 将起点 S 加入开放列表 OPEN, 初始化关闭列表 CLOSE 为空集
- (4) 当终点 T 不在关闭列表 CLOSE 中时, 执行循环:
- (5) 从开放列表 OPEN 中选择 f 值最小的节点 pred
- (6) 查找 pred 的所有可行相邻节点, 并将它们加入到 Suc 列表中
- (7) 遍历每一个相邻节点 suc:
- (8) 计算 $g(suc)=g(pred)+o(pred, suc)$
- (9) 计算 $f(suc)=g(suc)+h(suc)$
- (10) 如果 suc 节点已在开放列表 OPEN 中:
- (11) 如果新计算的 $f(suc)$ 小于 OPEN 中 suc 的 f 值:
- (12) 更新 OPEN 中 suc 的 f 值为新的 $f(suc)$
- (13) 否则:
- (14) 将 suc 节点加入开放列表 OPEN, 并设置其 f 值为 $f(suc)$
- (15) 从开放列表 OPEN 中移除节点 pred
- (16) 将节点 pred 加入关闭列表 CLOSE

1.3 深度学习

深度学习的方法有 Q-learning 和 Sarsa。Q-learning 算法是一种非策略强化学习算法。该算法利用每一步的值来执行下一步行动。基于

Q-Learning 算法的代理只能根据当前状态判断下一步行动, 而不了解整体环境。Q-learning 是强化学习算法中基于价值的算法。Q 指的是在一定时间、一定状态下采取某种行动的预期收益。环境会根据代理的行动反馈相应的收益, 因此该算法的主要思想是在状态和行动之间构建一个 Q 值表, 然后根据 Q 值选择能获得最大收益的行动。但 Q-learning 每次都会选择预期收益最高的行为, 在训练过程中可能无法探索其他可能的行为, 甚至会进入“局部最优”。Sarsa 是状态-行为-奖励-状态-行为, 它也是以 Q 表模式存储行为值函数。不同的是, Sarsa 的更新方式与 Q-learning 不同, 它的特点是先行动, 再更新, 会在行动后更新数据, 其伪代码如表 4 所示。

表 4 Q-learning 算法的伪代码

Table 4 Pseudo-code for the Q-learning algorithm

算法 4: Q-learning 算法

输入: 环境的状态集合、行动集合、奖励函数

输出: 优化后的 Q 值表

- (1) 初始化 Q 表, 为每一对状态和行动赋予初值, 通常为 0
- (2) 重复以下步骤直到 Q 表收敛:
 - a. 初始化状态 S
 - b. 选择并执行一个行动 A, 基于策略 π (如 ϵ -贪婪策略)
 - c. 观察结果状态 S' 和奖励 R
 - d. 选择 S' 状态下的最优行动 A' , 即 $\max Q(S', a)$
 - e. 根据公式更新 Q 值:
$$Q(S, A) \leftarrow Q(S, A) + \alpha [R + \gamma \max Q(S', a) - Q(S, A)]$$
其中, α 是学习率, γ 是折扣因子
 - f. 将状态 S 更新为 S'
- (3) 当 Q 表收敛或达到预定迭代次数时停止

说明: $Q(S, A)$ 表示在状态 S 下采取行动 A 的预期效用。

- R 是采取行动 A 后从环境中获得的即时奖励。 α (学习率) 控制学习过程中新信息的影响程度。 γ (折扣因子) 表示未来奖励的当前价值, 决定了对未来奖励的重视程度。 ϵ -贪婪策略在大部分时间选择最优行动, 有时则随机选择行动, 以探索新的状态。

2 仿真实验

2.1 环境搭建

通过使用 Matlab 作为实验工具。要模拟实验, 首先要设置环境。路径规划的定义是从起点到终点避开障碍物的可行路线。根据这一要求, 创建了一个长 20 个单位、宽 20 个单位的栅格迷宫。将它以网格的形式呈现如图 1 所示。绿色小方块是实验机器人, 初始位置位于迷宫的左上角。黑

色方块代表障碍物。相比之下，白色方块没有任何属性。机器人可以在整个迷宫中自由移动。当机器人移动到一个方格时，它可以移动到相邻的方格。迷宫右下角的紫色方格是终点。当机器人成功到达终点时，就获得了一条可行路径。不过，这种可行路径只有在不断学习和探索后才能找到。

在此基础上，为了验证算法在复杂动态环境下的适应性，实验中进一步引入了动态障碍物（在仿真结果图中以红色标记）。这些障碍物被建模为随机游走（Random Walk）实体，设定其移动速度为 1 格/步，即在智能体每执行一次移动决策时，动态障碍物也会同步随机移动至其相邻的网格中。这种位置的实时随机突变旨在模拟现实场景中不可预测的行人或移动设备，迫使算法必须具备在线重规划的能力，而非仅仅依赖对静态地图的记忆。

其次，定义移动机器人在迷宫中的动作，将以图 1 为基础。对于静态障碍物或动态障碍物占据的格子与其直接相邻的移动行为设置极大的负奖励(-100)，以防止算法选择穿越障碍物的路径。普通可通行区域的移动行为设置较小的负奖励（-0.04），鼓励算法寻找到达目标的最短路径。向目标点的移动提供正奖励（100），以吸引算法快速有效地到达终点。通过选择不同的移动方向（上/下/左/右），当前位置会随之改变，从而产生不同的结果。根据定义的场景，构建了一个奖励矩阵来反映从任一格到另一格的即时奖励值。奖励矩阵的主要作用是指导 Q-learning 算法更新其策略，以寻找从起点到终点的最优路径。

2.2 实现 Q-learning

Q-learning 是路径规划中一种典型的非策略方法。非策略指的是学习策略与执行策略不同，这在 Q-learning 策略中有所体现。Q-learning 的关键等式如下：

$$Q(s,a) \leftarrow Q(s,a) + \alpha(r + \gamma \max_{a'} Q(s',a') - Q(s,a)) \quad (2)$$

式(2)中， $Q(s,a)$ 是当前状态 s 下采取行动 a 的现有 Q 值； α 是学习率，决定新的信息覆盖旧信息的速度； r 是在状态 s 下采取行动 a 后获得的即时奖励； γ 是折扣因子，用于平衡即时奖励和未来奖励的重要性； $\max_{a'} Q(s',a')$ 是下一个状态 s' 下所有可能行动的最大 Q 值，表示从下一状态起可能获得的最大回报。

2.3 实现 A*

通过设计的一个 20x20 的栅格地图，其中包括障碍物、起始点和目标点。起始点位于地图的左上角，而目标点设在右下角，多个障碍物散布于地图中，用以增加路径规划的复杂度。在算法开始时，起始节点被添加到开放列表中。此列表存储所有待考察的节点，而关闭列表则存储已经考察过的节点。

从开放列表中选取 $F(x)$ 值最小的节点作为当前节点。将当前节点移至关闭列表，表示该节点已经被考察。遍历当前节点的所有相邻节点（上、下、左、右以及可能的斜向移动），对于每一个节点，计算其 $G(x)$ 、 $H(x)$ 和 $F(x)$ 值。如果相邻节点未被访问过，将其添加到开放列表中；如果已在开放列表中但找到了一个更佳的路径，则更新其路径成本。重复节点扩展过程，直至目标节点被加入到关闭列表，此时，算法找到了从起始点到目标点的最佳路径。通过从目标节点沿父节点连线回溯至起始节点，即可构建完整的路径。

2.4 仿真实验

环境初始化、参数配置、开放列表与关闭列表管理、搜索过程、路径回溯、结果分析与可视化。通过上述步骤，实现 A* 算法的模拟，仿真结果如图 2 所示。






图 2 A*算法下路径规划图

Fig.2 Path planning diagram under A* algorithm


从图 2 中路径可以分析出，路径从左上角开始，向右下角目标点蜿蜒前进。路径成功避开了所有障碍物，呈现多次转折以适应环境布局。实际路径长度为 34 步，相比于无障碍情况下的直线最短路径 29 步，效率略有降低。这种增加主要是由于绕过障碍物造成的必要迂回。障碍物密度为图中黑色格所占比例，计算结果显示约为 15%，表明障碍物对路径选择具有显著影响。路径的直线性与理想直线路径的偏差表明，所用启发式函数在处理特定障碍布局时效果良好，能够有效指导算法规避障碍。A* 算法在本实验设置中展示了良好的路径规划能力，能够有效应对复杂的环境障碍。尽管路径长度略长于理想最短路径，算法仍然成功找到了一条有效的通路到达目的地。随后，利用相同环境对 Q-learning 算法进行仿真验证。通过调整迭代参数，观察智能体在不同学习阶段的路径演化过程，仿真结果如图 3 所示。




(a) 迭代次数 10 次路径图



(b) 迭代次数 20 次路径图



(c) 迭代次数 40 次路径图



(d) 迭代次数 50 次路径图

图 3 Q-learning 算法下的路径图

Fig.3 Path diagram under Q-learning algorithm

从路径迭代图 4 中可分析出, X 轴标记为“迭

代次数”, 范围从 0~50; Y 轴标记为“路径长度/步”。在迭代初期, 性能指标有较大的波动, 表明在早期阶段, 算法可能在探索多个路径选项, 或者算法初始时对环境的了解还不足以产生稳定的输出。随着迭代次数的增加, 性能指标的波动逐渐减小。这表明算法可能开始收敛到某种解决方案, 随着学习的进行, 对环境的理解逐渐增强, 产生更稳定的结果。最后在 50 次迭代的阶段, 性能指标显著平稳并保持在一个较低的水平, 路径长度保持在 34 步。

为了直观对比两种算法在静态环境下的性能差异, 实验数据统计结果如表 5 所示。




图 4 Q-learning 路径迭代次数

Fig.4 Number of Q-learning path iterations

表 5 两种算法的对比结果表

Table 5 Table of comparison results of the two algorithms

名称	路径长度/步	计算时间/s
A*算法	29	7.8
Q-learning 算法	34	12.1

A*算法倾向于更直接和更短的路径, 因为它直接计算从当前节点到目标的最短路径。而 Q-learning 算法可能在早期学习阶段探索较多的路径, 路径长度和时间效率不如 A*算法。A*算法适用于已知环境中的路径规划问题, 而 Q-learning 更适合于那些环境动态变化或先验未知的情况, 可以通过与环境的交互逐渐学习最优策略, 如图 5 所示。

绿色路径显示了从起点 (左上角的黄色方块) 到终点 (右下角的紫色方块) 的一条路线。路径避开了障碍物, 并在某些区域选择了较为曲折的路线, 是在避开红色标记区域 (动态障碍物)。

算法在动态环境下的路径迭代收敛情况如图 6 所示。从图中可以看出, 在动态干扰下, 虽然初期路径长度波动较大, 但智能体最终仍能通过自

主学习收敛至稳定状态。




图5 动态环境下 Q-learning 路径图

Fig.5 Q-learning path diagram in a dynamic environment




图6 动态环境下 Q-learning 路径迭代次数

Fig.6 Number of Q-learning path iterations in a dynamic environment

2.5 Q 表的解释

为了分析算法的决策逻辑，算法学习到的部分 Q 值矩阵分布如图 7 所示。通过一个 5x5 的 Q 表来展示 Q-learning 算法在路径规划中的应用。Q 表中的每个单元格代表在特定状态下采取特定动作的预期效用 (Q 值)。Q 表初始化时，大部分单元格的 Q 值被设定为 0.5000，这是算法学习前的默认值，表示初始状态下对动作效用的基线预估。通过对 Q 表的详细分析，观察到部分状态-动作对的 Q 值显著高于初始化值，如表中第 2 行的第 1 和第 3 个动作，第 3 行的第 2 个动作，第 4 行的第 2 个动作，以及第 5 行的第 3 个动作。这些较高的 Q 值指示在特定状态下，这些动作相对其他动作有更高的预期奖励，且可能是实现最优路径的关键步骤。这些结果表明 Q-learning 算法能够有效地从交互中学习，通过不断更新 Q 值，逐渐形成针对特定任务的策略。高 Q 值的动作反映了算法在多次迭代后识别出的高效动作，表明这些动

作在达到目标状态时可能具有较高的奖励效益。

	1	2	3	4	5
1	0.5000	10.0100	0.5000	0.5000	0.5000
2	10.0004	0.5000	10.0184	0.5000	0.5000
3	0.5000	10.0139	0.5000	10.0173	0.5000
4	0.5000	0.5000	10.0137	0.5000	10.0040
5	0.5000	0.5000	0.5000	10.0135	0.5000

图7 Q-learning 算法下部分 Q 值

Fig.7 Partial Q-values under Q-learning algorithm

3 结 论

通过在 20×20 网格化仿真环境中系统对比 A* 算法与 Q-learning 算法的路径规划性能，研究发现：静态环境下 A* 算法在路径长度 (29 步 vs 34 步) 和搜索时间 (7.8 s vs 12.1 s) 上分别优于 Q-learning 算法 17.2% 和 35.5%，验证了启发式算法在已知环境下的高效性；动态障碍场景中 Q-learning 算法通过自适应更新 Q 表，在 12 次迭代内收敛至稳定策略，避障成功率达 100%，而 A* 算法规划成功率仅 62.3%，提升 37.7%，展现出强化学习在动态环境下的显著优势。实验采用 ϵ -贪心策略、学习率 $\alpha=0.1$ 和折扣因子 $\gamma=0.9$ ，Q-learning 算法在前 30 次迭代中波动较大 ($\sigma=8.7$ 步) 但第 34 次后稳定收敛。研究首次在相同条件下系统对比了两类算法在不同环境下的性能差异，提出了基于自适应 Q 表更新的策略优化方法，通过 50 次重复实验验证了算法收敛性和稳定性，这为后续集成高维感知的导航系统打下了逻辑地基，对于环境相对结构化的仓储物流等场景具有实际参考价值。未来研究可结合深度神经网络优化状态空间表示，引入多智能体强化学习框架实现多机器人协同，在真实三维环境中验证算法性能，探索启发式与强化学习的混合策略，通过增量式更新和并行计算提升实时性能，推动智能路径规划技术在更广泛场景中的应用。

参考文献 (References):

- [1] 孙鹏耀, 黄炎焱, 潘尧. 基于改进势场法的移动机器人路径规划[J]. 兵工学报, 2020, 41(10): 2106-2121.
SUN Pengyao, HUANG Yanyan, PAN Yao. Path planning of mobile robots based on improved potential field algorithm[J]. Acta Armamentarii, 2020, 41(10): 2106-2121.
- [2] 王旭, 朱其新, 朱永红. 面向二维移动机器人

的路径规划算法综述[J]. 计算机工程与应用, 2023, 59(20): 51-66.

WANG Xu, ZHU Qixin, ZHU Yonghong. Review of path planning algorithms for mobile robots[J]. Computer Engineering and Applications, 2023, 59(20): 51-66.

- [3] 林韩熙, 向丹, 欧阳剑, 等. 移动机器人路径规划算法的研究综述[J]. 计算机工程与应用, 2021, 57(18): 38-48.

LIN Hanxi, XIANG Dan, OUYANG Jian, et al. Review of path planning algorithms for mobile robots[J]. Computer Engineering and Applications, 2021, 57(18): 38-48.

- [4] 何丽, 姚佳程, 廖雨鑫, 等. 深度强化学习求解移动机器人端到端导航问题的研究综述[J/OL]. 计算机工程与应用. <https://kns.cnki.net/kcms/detail/11.2127.tp.20240407.1558.002.html>.

HE Li, YAO Jiacheng, LIAO Yuxin, et al. Summary of research on deep reinforcement learning for solving the end-to-end navigation problem of mobile robots[J/OL]. Computer Engineering and Applications. <https://kns.cnki.net/kcms/detail/11.2127.tp.20240407.1558.002.html>.

- [5] 李明, 叶汪忠, 燕洁华. 基于深度强化学习的沙漠机器人路径规划[J]. 系统仿真学报, 2024, 36(12): 2917-2925.

LI Ming, YE Wangzhong, YAN Jiehua. Path planning of desert robot based on deep reinforcement learning[J]. Journal of System Simulation, 2024, 36(12): 2917-2925.

- [6] 董明泽, 温庄磊, 陈锡爱, 等. 安全凸空间与深度强化学习结合的机器人导航方法[J/OL]. 兵工学报. <https://kns.cnki.net/kcms/detail/11.2176.TJ.20240229.1058.002.html>.

DONG Mingze, WEN Zhuanglei, CHEN Xiaai, et al. Robot navigation method combining safe convex space with deep reinforcement learning[J/OL]. Acta Armamentarii. <https://kns.cnki.net/kcms/detail/11.2176.TJ.20240229.1058.002.html>.

- [7] GHARBI A. A dynamic reward-enhanced

Q-learning approach for efficient path planning and obstacle avoidance in mobile robotics[J]. Applied Computing and Informatics, 2024: 333-340.

- [8] MONTERO E, PICO N, GHERGHEREHCHI M, et al. Memory-driven deep-reinforcement learning for autonomous robot navigation in partially observable environments[J]. Engineering Science and Technology, an International Journal, 2025, 62: 101942.

- [9] RAJ R, KOS A. Intelligent mobile robot navigation in unknown and complex environment using reinforcement learning technique[J]. Scientific Reports, 2024, 14: 22852.

- [10] WANG Z, SONG S, CHENG S. Path planning of mobile robot based on improved double deep Q-network algorithm[J]. Frontiers in Neurorobotics, 2025, 19: 1512953.

- [11] ABDI A, ADHIKARI D, PARK J H. A novel hybrid path planning method based on Q-learning and neural network for robot arm[J]. Applied Sciences, 2021, 11(15): 6770.

- [12] ALHASSOW M M, ATA O, ATILLA D C. Car-like robot path planning based on voronoi and Q-learning algorithms[C]//Proceedings of the International Conference on Engineering and Emerging Technologies. Piscataway: IEEE Press, 2021: 1-4.

- [13] YANG Y, LI J, PENG L. Multi-robot path planning based on a deep reinforcement learning DQN algorithm[J]. CAAI Transactions on Intelligence Technology, 2020, 5(3): 177-183.

- [14] DIAO Y, LU B, GUAN Y. Research on guidance method of hypersonic vehicle based on reinforcement learning and dynamic surface control[C]//Proceedings of the 3rd International Symposium on Automation, Information and Computing. SCITEPRESS - Science and Technology Publications, 2022: 651-657.

- [15] SACHAN S, PATHAK P M. Addressing unpredictable movements of dynamic obstacles with deep reinforcement learning to ensure safe

navigation for omni-wheeled mobile robot[J].
Proceedings of the Institution of Mechanical
Engineers, Part C: Journal of Mechanical
Engineering Science, 2025, 239(4): 1267-1293.

- [16] 王中玉, 曾国辉, 黄勃, 等. 改进 A*算法的
机器人全局最优路径规划[J]. 计算机应用,
2019, 39(9): 2517-2522.

WANG Zhongyu, ZENG Guohui, HUANG Bo,
et al. Global optimal path planning for robots
with improved A* algorithm[J]. Journal of
Computer Applications, 2019, 39(9):
2517-2522.

- [17] DAS P K, BEHERA H S, PRADHAN S K, et al.
A modified real time A* algorithm and its
performance analysis for improved path
planning of mobile robot[M]//Computational
Intelligence in Data Mining - Volume 2. New
Delhi: Springer India, 2014: 221-234.

- [18] DUCHOŇ F, BABINEC A, KAJAN M, et al.
Path planning with modified A* algorithm for a
mobile robot [J]. Procedia Engineering, 2014,
96: 59-69.

- [19] LI W, HUANG J, SUN Y. A* multi-strategy
improved A algorithm for global path planning
of mobile robots [J]. International Journal of
Computational Intelligence Systems, 2024,
17(1): 9.

- [20] KABIR R, WATANOBÉ Y, ISLAM M R, et al.
Enhanced robot motion block of A-star
algorithm for robotic path planning[J]. Sensors,
2024, 24(5): 1422.