

信息与控制
Information and Control
ISSN 1002-0411, CN 21-1138/TP

《信息与控制》网络首发论文

题目：复杂环境下基于强化学习与灰狼优化的多无人机路径规划算法
作者：常绪成，朱锋，张心慧，党帅龙，王敬宇，胡繁
DOI：10.13976/j.cnki.xk.2025.3482
收稿日期：2025-11-10
网络首发日期：2026-04-21
引用格式：常绪成，朱锋，张心慧，党帅龙，王敬宇，胡繁. 复杂环境下基于强化学习与灰狼优化的多无人机路径规划算法[J/OL]. 信息与控制.
<https://doi.org/10.13976/j.cnki.xk.2025.3482>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

复杂环境下基于强化学习与灰狼优化的多无人机路径规划算法

常绪成¹, 朱 锋², 张心慧², 党帅龙², 王敬宇², 胡 繁²

1. 郑州航空工业管理学院自动化学院, 河南 郑州 450046;

2. 郑州航空工业管理学院航空宇航学院, 河南 郑州 450046

基金项目: 中国高校产学研创新基金项目(2024ZY019); 河南省科技攻关项目(262102221005, 252102220056, 252102221025); 河南省校企协同创新项目(26AXQXT109); 郑州航院研究生教育创新计划基金项目(2025CX141); 河南省自然科学基金面上项目(252300421888); 航空科学基金项目(20200001055001); 郑州航院科研团队项目(24ZHTD01003); 河南省高等学校重点科研项目(26B590002)

通信作者: 朱锋, zhuf@zua.edu.cn 收稿/录用/修回: 2025-11-10/2026-01-04/2026-02-06

摘要

针对复杂环境下传统多无人机路径规划算法存在的收敛速度慢、易陷入局部最优与适应性不足等问题, 提出了一种基于灰狼优化(GWO)算法与强化学习的多无人机3维路径规划策略。为了提高复杂环境下传统GWO算法的路径规划综合性能, 通过设计动态非线性收敛因子增强算法前期探索能力与后期精度; 引入莱维飞行(Lévy flight)策略提升跳出局部最优的概率; 优化位置更新策略平衡全局搜索与局部开发效率。为进一步提高算法在复杂环境下的适应性, 将深度Q网络(DQN)与改进的灰狼优化算法深度融合, 并对DQN的状态空间与奖励函数进行优化设计。在不同场景下, 对本文提出的DQN-GWO算法进行对比仿真实验。实验结果表明, 与传统优化算法相比, DQN-GWO算法在保持运行时间相近的同时, 其收敛路径适应度平均提升了4%~6%, 路径长度降低了2%~8%, 最大转向角降低了30%~60%, 显著提高了复杂环境下规划路径的质量与鲁棒性, 为多无人机在复杂场景中的协同路径规划提供了一种有效的智能优化解决方案。

关键词

多无人机
灰狼优化(GWO)算法
强化学习
路径规划
中图法分类号: TP242
文献标志码: A

Multi-UAV Path Planning Algorithm Based on Reinforcement Learning and Grey Wolf Optimization in Complex Environments

CHANG Xucheng¹, ZHU Feng², ZHANG Xinhui², DANG Shuailong², WANG Jingyu², HU Fan²

1. School of Automation, Zhengzhou University of Aeronautics, Zhengzhou 450046, China;

2. School of Aerospace Engineering, Zhengzhou University of Aeronautics, Zhengzhou 450046, China

Abstract

To address the issues of slow convergence, susceptibility to local optima, and insufficient adaptability in traditional multi-UAV path planning algorithms under complex environments, we propose a multi-UAV 3D path planning strategy based on the grey wolf optimizer (GWO) and reinforcement learning. To improve the comprehensive path planning performance of the

Keywords

multi-UAV;
grey wolf optimization
(GWO) algorithm;
reinforcement learning;

traditional GWO algorithm in complex environments, we design a dynamic nonlinear convergence factor to enhance the algorithm's early-stage exploration ability and late-stage accuracy, introduce a Lévy flight strategy to increase the probability of escaping local optimality, and optimize a position update strategy to balance the efficiency of global search and local exploitation. To further improve the algorithm's adaptability in complex environments, we integrate the deep Q-network (DQN) into the improved GWO algorithm, and optimize the state space and reward function of DQN. Comparative simulation experiments of the proposed DQN-GWO algorithm are conducted in different scenarios. The results show that compared with traditional optimization algorithms, the DQN-GWO algorithm maintains comparable runtime while achieving an average 4% ~ 6% improvement in path fitness, a 2% ~ 8% reduction in path length, and a 30% ~ 60% decrease in maximum steering angle. This significantly enhances the quality and robustness of planned paths in complex environments, providing an effective intelligent optimization solution for collaborative path planning among multiple UAVs in complex environments.

0 引言

无人机凭借作业范围广、机动性强等优势,已广泛应用于地理测绘、应急救援和军事侦察等领域,成为航空领域的研究热点之一。然而,单无人机在执行复杂任务时存在覆盖范围有限、任务响应效率较低等局限性,而多无人机协同系统通过任务分工与并行执行,能够显著扩大作业覆盖范围并提升任务完成效率。多无人机协同系统的关键技术涵盖路径规划、编队控制与任务分配等方面,使得多无人机系统在复杂任务中展现出显著优势,也使其成为当前无人机研究的重要方向。

多无人机路径规划作为多无人机协同系统中的关键技术之一,相关研究已取得一定的进展。例如,通过改进 A*、DWA 等经典搜索算法,实现了静态环境下的高效无人机避障路径规划^[1-2];遗传算法通过种群进化机制,可在复杂环境中搜索无人机的近似最优路径^[3]。粒子群优化算法借鉴了群体智能行为,能够快速获得无人机的可行路径方案^[4];同时,强化学习方法在无人机路径规划中的应用也更加深入,借助历史飞行数据训练模型,增强了无人机对动态环境的适应性^[5-6]。然而,随着环境复杂度的上升,现有算法在复杂地形中还有着收敛速度慢、易陷入局部最优、适应性不足等局限,导致路径规划难以满足复杂场景的应用需求。

针对复杂环境中算法收敛速度慢的问题,杜云等^[7]提出改进粒子群算法,通过线性化调整学习因子并引入遗传变异策略,显著提高了收敛速度和规划成功率;YU 等^[8]则提出混合灰狼优化与差分进化的 HGWODE 算法,通过改进位置更新方程和引入基于排名的变异策略,在提升收敛速度的同时显著增强了算法的全局寻优能力。针对传统算法

易陷入局部最优的问题,曹建秋等^[9]创新性地融合粒子群算法与蚁群算法,在信息素更新中引入适应度值,结合贪心策略优化校正点运算,大幅提升了路径规划的精度和效率;MEIDANI 等^[10]提出的自适应 GWO 通过动态参数调整,显著改善了探索-开发的平衡性。针对算法适应性不足的问题,ARULKUMARAN 等^[11]指出,DQN 通过引入经验回放和目标网络来稳定学习过程,有效解决了适应性不足的问题。在现有的研究中,灰狼优化算法表现出结构简单、参数少、收敛性能好等优点,且 DQN 在处理高维状态和感知不确定性方面表现出独特优势。由此,考虑将 DQN 与改进 GWO 相融合。但两者在应对复杂路径规划问题时仍存在改进空间:GWO 在全局搜索与局部开发之间的平衡机制尚不完善;DQN 决策效率仍有待提升^[12]。

结合上述问题与研究思路,本文提出一种 DQN-GWO 算法,设计了动态非线性收敛因子、引入莱维飞行策略、优化位置更新策略、并通过深度 Q 网络(DQN)与改进灰狼算法的融合优化无人机路径规划算法框架,利用 DQN 生成的路径点序列指导改进灰狼优化算法的局部搜索过程,使得该算法在保持灰狼优化算法社会等级结构优势的同时,改善其复杂环境中的全局搜索能力和收敛性能。

1 无人机状态模型

1.1 无人机运动学模型

为了便于研究无人机路径规划的过程,本文首先建立无人机的运动学模型,通过简化无人机垂直与水平运动的耦合问题,将无人机简化为质点,以便于运动学的分析。在上述条件下,无人机状态方程为

$$\begin{cases} \dot{x} = v \cos \theta \cos \psi \\ \dot{y} = v \cos \theta \sin \psi \\ \dot{z} = v \sin \theta \\ \dot{\psi} = \omega_\psi \\ \dot{\theta} = \omega_\theta \end{cases} \quad (1)$$

式中, (x, y, z) 表示无人机在 X 、 Y 、 Z 轴的位置坐标; $\psi, \theta, v, \omega_\psi, \omega_\theta$ 分别表示为无人机的航向角、俯仰角、沿机身前向的飞行速度、航向角速度及俯仰角速度。

对状态变量施加约束: 飞行速度限制在 $v \in [v_{\min}, v_{\max}]$, 其中, $v_{\min} = 0 \text{ m/s}$, $v_{\max} = 10 \text{ m/s}$ (典型小型无人机最大水平速度); 转向角速度 $|\omega| \leq \omega_{\max}$, 对应最大转向角变化率不超过 $25^\circ/\text{s}$:

$$\omega_{\max} = \frac{25\pi}{180} \text{ rad/s} \quad (2)$$

1.2 环境状态模型

多无人机路径规划涉及无人机运动学模型、环境建模、算法设计等问题, 其中环境状态的建模是路径规划的核心内容之一^[13]。环境状态向量作为无人机感知外部环境与自身状态的量化载体, 包括无人机位置、目标点位置、障碍物等信息。

无人机初始位置用 3 维坐标表示, 如式 (3) 所示:

$$\mathbf{P}_s = [x_s, y_s, z_s] \quad (3)$$

式中, x_s, y_s, z_s 分别为无人机在 X 、 Y 、 Z 轴的初始坐标。

目标点为路径规划的目的地, 用 3 维坐标表示:

$$\mathbf{P}_g = [x_g, y_g, z_g] \quad (4)$$

式中, x_g, y_g, z_g 分别为目标点在 X 、 Y 、 Z 轴的坐标。

本文将环境中障碍物类型设定为威胁性障碍物、3 维复杂地形和动态障碍物。威胁性障碍物以雷达、禁飞区为主, 当无人机进入威胁范围时, 虽不会直接造成物理损伤, 但会导致无人机暴露等风险。因此, 在路径规划过程中, 必须确保与之保持安全距离, 以实现有效规避。其中, 雷达的有效探测范围设定为球体, 其有效探测范围:

$$\mathcal{S} = \{(x, y, z) \in \mathbb{R}^3 \mid \sqrt{(x-x_r)^2 + (y-y_r)^2 + (z-z_r)^2} \leq R_r\} \quad (5)$$

式中, x_r, y_r, z_r 分别为雷达中心点在 X 、 Y 、 Z 轴的坐标, R_r 表示雷达最大探测半径。

禁飞区的范围用圆柱表示:

$$\mathcal{S}_{\text{nf}} = \{(x, y, z) \in \mathbb{R}^3 \mid \sqrt{(x-x_{\text{nf}})^2 + (y-y_{\text{nf}})^2} \leq R_{\text{nf}}, 0 \leq z \leq H_{\text{nf}}\} \quad (6)$$

式中, $(x_{\text{nf}}, y_{\text{nf}})$ 为禁飞区中心点坐标, $R_{\text{nf}}, H_{\text{nf}}$ 分别

表示禁飞区的半径范围及高度。

3 维复杂地形主要以基础地形与山峰为主。首先建立基础地形波形函数, 通过不同频率和方向的周期性变化模拟自然地形的波动特征:

$$z_b(x, y) = \sin(y + \phi_1) + k_1 \sin x + k_2 \cos(\omega_1 r^2) + k_3 \cos y + k_4 \sin(\omega_2 r^2) + k_5 \cos y \quad (7)$$

式中, ϕ_1 为沿 y 方向正弦波的相位偏移量; k_1, k_2, k_3, k_4, k_5 分别为各波形成分的振幅调节系数; ω_1 和 ω_2 表示径向波纹的频率参数, 用于控制地形在径向的波动密度; $r^2 = x^2 + y^2$ 表示计算点到坐标原点的径向距离平方, 用于生成具有环形特征的地形起伏。

其次, 利用高斯函数建立独立山峰:

$$G_i(x, y) = h_i \exp\left(-\left(\frac{(x-\mu_{x,i})^2}{2\sigma_{x,i}^2} + \frac{(y-\mu_{y,i})^2}{2\sigma_{y,i}^2}\right)\right) \quad (8)$$

式中, $i = 1, 2, \dots$; N 表示山峰总个数; $(\mu_{x,i}, \mu_{y,i}, h_i, \sigma_{x,i}, \sigma_{y,i})$ 为第 i 座山峰的参数, $(\mu_{x,i}, \mu_{y,i})$ 为山峰的中心坐标, h_i 为山峰的高度, $\sigma_{x,i}, \sigma_{y,i}$ 为山峰宽度参数。

为了确保地形始终呈现最显著的特征, 模拟真实世界中的山峰地形, 通过最大值运算融合两种地形特征:

$$Z(x, y) = \max(z_b(x, y), z_m(x, y)) \quad (9)$$

式中, $z_m(x, y) = \sum_{i=1}^3 G_i(x, y) + h_0$ ($h_0 = 0$) 为高斯地形的总山峰地形函数。

动态障碍物主要以移动球体为主。动态障碍物在 3 维空间中按圆周轨迹进行运动, 其位置是时间的函数, 可表示为

$$\mathbf{P}_a = [x_a(t), y_a(t), z_a(t), R_a] \quad (10)$$

式中, $x_a(t), y_a(t), z_a(t)$ 为动态障碍物在 X 、 Y 、 Z 轴的随时间变化的位置坐标, R_a 表示移动球体的半径。运动规律为

$$\begin{cases} x_a(t) = x_a(0) + R_c \cos(\omega_c t) \\ y_a(t) = y_a(0) + R_c \sin(\omega_c t) \\ z_a(t) = z_a(0) \end{cases} \quad (11)$$

式中, $x_a(0), y_a(0), z_a(0)$ 为动态障碍物在 X 、 Y 、 Z 轴的初始位置坐标; R_c 表示移动球体的运动圆周半径, 单位为 km ; ω_c 表示移动球体的角速度, 单位为 rad/s 。

通过构建上述结构化的环境状态模型, 本文将复杂的物理空间信息抽象为高效的数学模型, 从而显著缩小了路径规划算法的决策空间, 降低了无人机路径规划中的计算复杂度, 确保了仿真环境既贴

近现实又具备高效的计算特性。

2 DQN-GWO 算法设计

2.1 GWO 算法及其优化设计

作为一种受自然界启发的元启发式优化算法，灰狼优化算法模拟了灰狼群体的捕猎行为，其核心在于抽象灰狼种群的社会等级制度(α 、 β 、 δ 三级分层)，通过数学建模再现其围捕、追踪及包围猎物的种群行为。算法具备较强的全局寻优能力与较好的空间探索效能，适用于多无人机的路径规划^[14]。

GWO 的计算流程如图 1 所示。首先，设定灰狼种群、收敛因子 a 及系数向量 A 、 C ；接着，计算所有灰狼个体的适应度值，选出适应度最优的 3 头狼 α 、 β 、 δ ；随后，更新灰狼个体的位置，以模拟狼群实际围猎行为。位置更新后，重新计算个体适应度并更新领导狼 α 、 β 、 δ 。每次迭代完成后，计数器 t 增加 1，并判断是否达到最大迭代次数 $t_{\max}$ 。若未达到，则继续循环执行位置更新和适应度计算；若达到，则算法终止^[15-16]。

该算法利用 α 、 β 、 δ 狼的层级引导机制，在搜索过程中通过依赖少数领导个体来指引种群更新，因此参数少、计算效率高。然而，这种依赖领导个体的引导机制使得在处理复杂高维问题时，若领导狼群过早聚集于一个非全局最优点，整个种群将因缺乏有效的变异或扰动机制而迅速陷入该区域，导致陷入局部最优、收敛速度受限的问题。

针对灰狼优化算法在处理复杂、高维优化问题时存在的易陷入局部最优、收敛速度受限等问题，本文对 GWO 算法进行了改进，并引入了非线性参数控制策略、莱维飞行策略及改进的位置更新策略，以提升算法在复杂环境下的综合性能^[17-18]。相较于传统 GWO 算法，改进的 GWO 在保持全局搜索能力的同时，有效避免了局部最优与早熟收敛现象，为复杂环境下的路径规划问题提供了新的解决方案。

改进的 GWO 算法流程如图 2 所示。首先，计算非线性收敛因子 a_G ，以平衡算法前期的全局探索能力与后期的局部寻优能力。若非首次迭代，则对灰狼种群进行聚类分组，以维持种群多样性。随后，在各子群内更新 α 、 β 、 δ 领导狼的位置信息。与此同时，算法在路径规划过程中引入了莱维飞行策略，通过对个体位置施加随机扰动来有效避免算法陷入局部最优。位置更新过程中，每一维度的位置更新量均依据改进的灰狼位置更新公式计算。最




图 1 GWO 算法流程图

Fig.1 GWO algorithm flowchart

后，记录当前最优适应度值，如此循环直至满足迭代终止条件。

2.1.1 非线性参数控制策略

传统 GWO 算法的线性参数控制策略在处理复杂优化问题时，存在探索与开发能力难以动态平衡的局限性。为解决该问题，本文采用了一种非线性递减策略，以更有效地动态调节参数。该策略通过引入非线性递减的调节因子，构建了一个具有自适应特性的参数，其更新策略为

$$A' = ma_G r_1 - a_G, C' = nr_2 \quad (12)$$

式中， $m=2$ ， $n=2$ ； r_1 、 r_2 是 $[0,1]$ 的随机向量。根据仿生学原理，灰狼具有捕猎前期包围缓慢、后期攻击快速的特性，据此设计非线性递减参数 a_G ：




图2 改进 GWO 算法流程图

Fig.2 Improved GWO algorithm flowchart

$$a_G = 2 \cos \left(\frac{\pi}{2} \frac{t_{ic}}{t_{ic,max}} \right) \quad (13)$$

式中, t_{ic} 是当前的迭代次数; $t_{ic,max}$ 是最大迭代次数。式 (13) 选用的余弦函数在 $[0, \pi/2]$ 区间内, 其 1 阶导数的绝对值由 0 逐渐增大, 符合搜索强度逐步加强的需求。动态调整机制使算法能够根据搜索进程和问题特性智能地平衡全局探索与局部开发, 有效避免了传统线性递减策略导致的探索-开发机制失调问题。

2.1.2 莱维飞行策略

为了克服传统 GWO 算法易于陷入局部最优的问题, 本文引入莱维飞行策略以优化其搜索行为。该策略是一种随机游走模型, 自然界中, 许多动物 (如信天翁、蜜蜂) 的觅食行为都遵循莱维飞行模式。其路径特征为在大尺度上具有长跳跃, 而在小

尺度上具有高频振荡, 能够有效增强搜索算法的全局探索能力, 极大程度上避免陷入局部最优的问题, 从而使得算法在解空间中能够更广泛地探索潜在解区域, 其计算公式为

$$s = \frac{u}{|v|^{1/\beta_L}} \quad (14)$$

式中, $u \sim N(0, \sigma_u^2)$, $v \sim N(0, 1)$, β_L 是莱维分布的特征指数, 用于控制分布形状; σ_u 是随机步长尺度参数, 用于控制步长幅度:

$$\sigma_u = \left(\frac{\Gamma(1+\beta_L) \cdot \sin(\pi\beta_L/2)}{\Gamma((1+\beta_L)/2) \cdot \beta \cdot 2(\beta_L-1)/2} \right)^{1/\beta_L} \quad (15)$$

式中, $\Gamma(\cdot)$ 为伽马函数。通过引入莱维飞行策略, 有效增强了 GWO 算法的全局探索能力, 使其能够广泛探测解空间中的潜在区域, 从而显著提升逃离局部最优的概率。避免了传统 GWO 陷入局部最优的困境。

2.1.3 改进灰狼位置更新策略

为了平衡全局搜索与局部开发效率, 本文对传统 GWO 的位置更新策略进行了改进。通过综合引入引导机制、惯性项及扰动策略, 并结合局部搜索加权与莱维飞行策略, 有效提升了算法的整体优化性能^[19-20]。具体而言, 改进后的位置更新不仅保留了 α 、 β 、 δ 领导个体的引导作用和邻域个体信息, 还引入了局部搜索调节因子 η 和莱维飞行随机扰动项, 从而构建了更加鲁棒的位置更新公式。这种改进机制有效平衡了全局探索与局部开发的关系, 在保持种群多样性的同时增强了局部搜索能力, 从而避免了传统线性加权更新方式容易导致的早熟收敛问题。改进的位置更新公式为

$$X_i(t_{ic}+1) = \eta(X_\alpha(t_{ic}) - A_G |X_\alpha(t_{ic}) - X_i(t_{ic})|) + (1-\eta)X_i(t_{ic}) + \lambda s \quad (16)$$

式中, $X_i(t_{ic})$ 是第 i 只灰狼在迭代次数 t_{ic} 时的位置; $X_\alpha(t_{ic})$ 表示 α 狼在迭代次数 t_{ic} 时的位置; λ 扰动强度, 随迭代指数衰减; η 是局部搜索因子, 取值范围为 $[0, 1]$, 在算法迭代过程中逐渐减小, 使得初期能够广泛搜索, 后期则专注于局部最优解的精细化搜索。该改进策略不仅提高了收敛精度, 有效防止算法过早收敛, 而且增强了在复杂问题中的适应性。

2.2 DQN 算法及优化设计

深度强化学习 (DRL) 是一种智能体通过与环境交互、获取奖励反馈来不断调整行为策略的学习方法。DQN 作为近年来深度强化学习领域的重要技术, 在经典 Q 学习算法的基础上引入深度神经网络, 显著提升了状态空间较大时的学习能力, 被广泛应用于复杂控制和路径规划任务^[21-22]。在无人机

路径规划任务中, DQN 算法能够通过持续感知当前环境、自主学习最优路径策略, 从而实现动态决策与在线调整。

2.2.1 DQN

DQN 的基本结构包括状态空间 S 、动作空间 A_D 、奖励函数 R 和策略函数 $\pi(s)$ 四个核心要素^[23]。其核心思想是利用深度神经网络来逼近最优 Q 函数, 通过评估在特定状态下采取不同动作所能获得的预期回报, 从而指导决策过程。

在无人机路径规划应用中, 无人机首先感知当前环境状态, 基于 S 贪婪策略选择执行动作; 执行该动作后, 环境反馈即时奖励和新的状态观测值; 系统将这些交互数据存入经验回放池, 并通过随机采样方式从中抽取训练样本更新网络参数。通过不断重复这一“交互-学习”的迭代过程, Q 网络逐渐收敛, 最终输出能够最大化长期回报的最优路径规划策略^[24]。

2.2.2 状态空间 S 和动作空间 A_D

在多无人机路径规划中, 合理设计状态空间 S 和动作空间 A_D 是实现高效策略学习的前提。结合完备性原则与独立性原则, 在包含所有影响决策的关键环境信息的同时保持各状态相对独立, 减少冗余信息, 基于上述原则构建状态空间:

$S = \{(x, y, z, d_{\text{goal}}, w_1, \dots, w_n) | x, y, z, d_{\text{goal}}, w_j \in \mathbb{R}\}$ (17)
 式中, (x_t, y_t, z_t) 表示当前状态下无人机坐标; $\{w_j\}$ 表示当前位置相对各类障碍物的威胁强度估计; d_{goal} 用于表示当前无人机与距目标点的欧氏距离:

$$d_{\text{goal}} = \sqrt{(x_t - x_g)^2 + (y_t - y_g)^2 + (z_t - z_g)^2} \quad (18)$$

本文选用四旋翼无人机为研究对象。结合完备性原则、可执行性原则与效率性原则, 在满足四旋翼无人机的物理约束的情况下, 覆盖其基本运动方向, 平衡算法计算效率。为此, 本文采用离散动作空间。无人机具有前进后退、左右偏航和上下俯仰六个动作^[25], 因此其动作空间是一个离散的有限集合, 定义为

$$\begin{aligned} A_D = & \{[x_1, y_1, z_1], [x_2, y_2, z_2], [x_3, y_3, z_3], \\ & [x_4, y_4, z_4], [x_5, y_5, z_5], [x_6, y_6, z_6]\} \\ = & \{[1, 0, 0], [-1, 0, 0], [0, 1, 0], \\ & [0, -1, 0], [0, 0, 1], [0, 0, -1]\} \end{aligned} \quad (19)$$

式中, 动作向量 $[x, y, z]$ 表示无人机在 X 、 Y 、 Z 坐标系下沿 x 、 y 、 z 所进行的动作: 取 1 或者 -1 表示沿 x 、 y 、 z 正或负方向移动; 取 0 表示在当前轴无移动。

2.2.3 奖励函数 R

为了提升无人机在路径规划中的环境探索效率

和路径规划的总体效果, 根据无人机的运动特性及环境的复杂性, 本文构建了一种综合性奖励函数 R , 以引导无人机在朝向目标点高效运动的同时, 有效规避各类障碍物, 从而在探索效率与飞行安全之间实现平衡。

为驱动无人机到达目标点, 对无人机进行渐进引导, 设置基础距离奖励 R_d 。 R_d 随接近目标而增强, 其计算公式为:

$$R_d = -k_1 d_{\text{goal}} \quad (20)$$

式中, k_1 为奖励系数, d_{goal} 取正值。

当无人机与目标点的距离越远, 得到的基础奖励就越小, 以此形成一种持续的驱动力, 促使无人机不断向目标点位置靠近。

为确认无人机是否到达目标位置, 设置目标位置到达奖励 R_r , 当无人机进入目标点邻域时给予大幅正向奖励:

$$R_r = \begin{cases} +100, & d_{\text{goal}} < 2g_s \\ 0, & \text{otherwise} \end{cases} \quad (21)$$

式中, g_s 为环境建模中所采用网格的最小单元。通过该设计, 能有效强化无人机完成抵达目标点这一核心任务的行为, 让无人机任务目标更加清晰, 显著提高其完成任务的驱动力。

为规避无人机碰到障碍物与威胁区, 以无人机安全为主, 设置障碍物碰撞惩罚 R_c :

$$R_c = \begin{cases} -500, & C(s) = \text{true} \\ 0, & \text{otherwise} \end{cases} \quad (22)$$

式中, 碰撞检测函数 $C(t)$ 的计算公式为

$$\begin{aligned} C(t) = & \left(\bigvee_{i=1}^{N_{\text{nf}}} \left(\sqrt{(x_t - x_i^{\text{nf}})^2 + (y_t - y_i^{\text{nf}})^2} \leq R_i^{\text{nf}} \right) \right) \\ & \vee \left(\bigvee_{j=1}^{N_r} \left(\sqrt{(x_t - x_j^r)^2 + (y_t - y_j^r)^2 + (z_t - z_j^r)^2} \leq R_j^r \right) \right) \\ & \vee \left(\bigvee_{l=1}^{N_a} \left(\sqrt{(x_t - x_{a,l}(t))^2 + (y_t - y_{a,l}(t))^2 + (z_t - z_{a,l}(t))^2} \leq R_l^a \right) \right) \\ & \vee \left(\bigvee_{k=1}^{N_p} \left(z_t \leq G_k(x, y) \right) \right) \end{aligned} \quad (23)$$

式中, N_{nf} 、 N_r 、 N_a 、 N_p 分别表示环境中禁飞区、雷达、动态障碍物和山峰个数。

综上所述, 最终的奖励值是由 UAV 从起始点到目标点路径中获得上述各项奖励与惩罚的总和 R :

$$R = \eta_1 R_d + \eta_2 R_r + \eta_3 R_c \quad (24)$$

式中, η_1 、 η_2 、 η_3 分别为 R_d 、 R_r 、 R_c 对应的权重。通过奖惩机制, 能够有效推动无人机在复杂环境中高效、安全地抵达目标位置。

2.2.4 Q 值更新

本文中 Q 值的更新遵循强化学习的时序差分 (TD) 学习的核心思想, 如式 (25) 所示。

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha_t (r_t + \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t)) \quad (25)$$

式中, $Q(s_t, a_t)$ 为当前状态 s_t 下采取动作 a_t 的估计价; α_t 是学习率, 用于控制更新步长; r_t 是执行动作 a_t 后获得的即时奖励; γ 为折扣因子, 用于表示未来奖励系数; $\max_{a'} Q(s_{t+1}, a')$ 表示在下一状态 s_{t+1} 下所有可能动作的最大 Q 值。

无人机通过不断训练, 逐步学习到最优策略。每次执行动作后, 它会根据获得的奖励和对未来状态的价值估计, 调整当前状态-动作对应的价值。随着迭代次数增加, Q 值会逐渐收敛到最优策略下的动作价值函数, 从而使无人机能够选择尽可能优的

路径策略。

2.3 DQN-GWO 融合设计

DQN 算法通过对复杂状态-动作映射关系建模, 并设置自适应的奖励函数, 将强化学习拓展至高维、非线性问题的求解中。在无人机路径规划领域, 该算法展现出了两个方面优势: 其一, 它能够在未知或部分可观测环境中进行策略学习, 适用于环境复杂、不确定性高的多无人机环境; 其二, 得益于深度学习强大的特征提取能力, DQN 可有效处理高维状态输入, 从而提升路径规划的性能。然而, DQN 存在全局探索效率低、对初始解依赖性高及收敛速度慢等固有缺陷。针对这些局限性, 本文采用改进灰狼优化算法进行补偿, 通过 3.1 节的优化设计及与 DQN 融合架构, 使融合算法能够展现出优异的全局搜索能力与快速的收敛速度。

基于上述分析, 本文构建了 DQN-GWO 混合优化模型, 其总流程如图 3 所示。




图 3 融合 DQN-GWO 算法流程图

Fig.3 Flowchart of the integrated DQN-GWO algorithm

图 3 中, DQN-GWO 算法部分是通过 DQN 与改进 GWO 的协同配合, 实现从全局路径搜索到局部精细优化的完整路径规划流程。在该结构中, DQN 作为局部策略学习器, 引导路径更新方向; 而 GWO 则负责在候选路径空间中进行全局搜索与快速收敛。

两者的协同配合体现在信息交互与策略互补上: 首先, 在每次迭代中, GWO 种群中的每个个体都会调用 DQN 的局部决策能力, 基于当前路径状

态生成有效动作集, 并通过 ε 贪心策略选择最优局部移动方向, 这种实时指导使得 GWO 的搜索过程具有了环境感知与自适应调整能力; 其次, DQN 通过经验回放缓冲区不断积累 GWO 搜索过程中产生的“状态-动作-奖励-下一个状态”四元组, 实现了从群体智能中学习优化经验的知识迁移。DQN-GWO 伪代码, 如算法 1 所示。

算法1 DQN-GWO算法

1. 输入 无人机数量 N , 最大迭代次数 $t_{\max}$, 搜索空间上下

界 $[X_{\min}, X_{\max}]$
 输出 最佳适应度值 f_{best} , 最佳位置 X_{best}

2. 初始化 Q-table $Q(s,a)$, 经验回放缓冲区 B , 基础动作集 A
3. 初始化种群位置 $X = [x_1, x_2, \dots, x_N]$, 领导狼 α 、 β 、 δ , 历史缓冲区 H
4. **for** iter = 1 to $t_{\max}$ **do**
5. $a_G = 2\cos((\pi/2)(t/t_{\max}))$
6. **for** $i = 1$ to N **do**
7. % 有效动作集生成
8. $A_{\text{valid}} = \text{get_valid_actions}(x_i(t), X_{\min}, X_{\max})$ % 边界+碰撞+角度约束
9. % DQN局部指导
10. **if** $\text{rand}() < 0.7$ and $\sim \text{isempty}(A_{\text{valid}})$ **then**
11. $a_i = \varepsilon\text{-greedy}(Q, x_i(t), A_{\text{valid}})$
12. $[x_{i,\text{next}}, r_i] = \text{take_action}(x_i(t), a_i)$
13. $\text{store_experience}(B, (x_i(t), a_i, r_i, x_{i,\text{next}}))$
14. $x_i(t) = x_{i,\text{next}}$
15. **end**
16. % GWO位置更新
17. $x_{\text{term}} = (x_{\alpha} + x_{\beta} + x_{\delta})/3$
18. $x_{\text{history}} = 0.3(x_{\text{best}} - x_i(t)) + 0.2\text{mean}(\Delta x)$
19. $x_{\text{levy}} = L(d, t, T)$
20. $x_i(t+1) = x_{\text{leader}} + x_{\text{history}} + x_{\text{levy}}$
21. % 更新领导狼与历史缓冲区
22. **if** $f(x_i(t+1)) < f(x_{\alpha})$ **then**
 更新 $(x_{\delta}, x_{\beta}, x_{\alpha}) \leftarrow (x_{\beta}, x_{\alpha}, x_i(t+1))$
23. **else if** $f(x_i(t+1)) < f(x_{\beta})$ **then**
 更新 $(x_{\delta}, x_{\beta}) \leftarrow (x_{\beta}, x_i(t+1))$

24. **else if** $f(x_i(t+1)) < f(x_{\delta})$ **then**
 $x_{\delta} = x_i(t+1)$
25. 更新历史缓冲区
26. $H \leftarrow x_i(t+1)$
27. **end**
28. **end**

3 仿真结果与实验分析

为验证 DQN-GWO 算法在复杂场景下的路径规划效果, 通过在 Matlab 2023b 中构建基于 $20 \text{ km} \times 20 \text{ km} \times 6 \text{ km}$ 的 3 维空间的仿真环境(网格的最小单元为 0.1 km), 在仿真中假设无人机的状态感知与控制系统处于理想状态, 且所有障碍物位置信息均已知。基于此环境, 本文开展了两组场景下的多起点多目标点仿真对比实验。每组对比实验独立测试 30 次, 根据实验结果从算法适应度、路径规划长度、算法运行时间和路径平滑度四个维度进行定量评估, 并与蚁群算法(ACO)、灰狼优化算法(GWO)和逐次凸逼近算法(SCA)进行对比分析, 并辅以 t 检验, 以验证 DQN-GWO 在复杂环境下的路径规划性能和协同优化效果。

仿真实验涉及无人机边界约束设置与障碍物具体参数设置^[26], 如表 1、表 2 所示。

3.1 基础场景下的多起点—多目标点路径规划任务

本文模拟了 3 架无人机在基础场景下, 从不同

表 1 无人机边界约束设置

Tab.1 UAV boundary constraint settings

参数	范围 /km
地图边缘约束(X坐标)	2~18
地图边缘约束(Y坐标)	2~18
高度约束	0~5

表 2 无人机路径规划中障碍物设置

Tab.2 Obstacle placement in UAV path planning

场景	禁飞区参数	雷达区参数	动态障碍物初始位置 运动圆周半径及角速度	山峰参数
基础场景	(15,5,1,5)	(10,14,2)	(10.5,6.7,1.5)	(8.5,5.4,1.9,2)
	(5,15,2,5)	(9,3,2)	(1.5, 0.01)	(10,12.5,1.8,2)
		(18,9,1.5)		(15,16,3,2,1.8)
复杂场景	(15,5,1,5)	(10,14,2)		(8.5,5.4,1.9,2)
	(5,15,2,5)	(9,3,2)	(10.5,6.7,1.5)	(10,12.5,1.8,2)
	(10,10,1.5,5)	(18,9,1.5)	(1.5, 0.01)	(15,16,3,2,1.8)(6.8,3.5,1.7,1.9)
		(7,17,2.5)		(13,4,4.5,1.6,2.1)

起点出发, 执行不同目标点任务(记为任务 1), 重点验证算法在基础场景下多机执行不同起点、不同目标点任务的协同鲁棒性。通过对比算法的算法适应度、路径长度、转角大小等, 验证 DQN-GWO 算法在基础协同任务中的有效性。该任务中的无人机起点坐标与目标点坐标如表 3 所示。

该实验独立测试了 30 次。图 4 以其中一次为例展示 ACO、SCA、GWO 和 DQN-GWO 的路径规划结果。实验结果数据如表 4~7 所示。多算法收敛曲线比较图和实验结果数据箱线图见图 5、图 6。

由图 4~6 和表 4~7 的仿真结果可知, 在基础场景下的多起点、多目标点路径规划任务中, DQN-

表 3 任务 2 初始参数设置

Tab.3 Task 2 initial parameter settings

无人机	起点	任务目标点
UAV1	(1,1,1)	(18,18,2.5)
UAV2	(2,2,1.5)	(17,17,3)
UAV3	(3,3,2)	(16,16,3.5)

GWO 保持着最优性能。从收敛特性来看, 图 5 显示 DQN-GWO 在迭代前期即表现出更快的收敛速度, 且最终稳定在更低的适应度水平, 说明其在基础场景下的多起点任务中能保持着高效的优化效率。图 6 的适应度分布与路径长度分布的对比进一




图 4 基础场景下的多起点、多目标点算法路径规划示意图

Fig.4 Path Planning Diagram of multi-start-point multi-target-point algorithm in basic scenarios

表 4 任务 1 中的各算法适应度
Tab.4 Fitness of each algorithm in Task 1

算法	UAV1适应度	UAV2适应度	UAV3适应度	总平均适应度
DQN-GWO	234.91±7.91	206.98±8.57	185.29±5.31	209.06
SCA	240.57±7.65	215.56±8.40	188.83±4.79	214.99
ACO	250.42±6.09	214.18±6.99	186.19±4.03	216.93
GWO	245.24±6.24	223.32±9.77	194.40±6.17	220.99

表 5 任务 1 中的各算法路径长度
Tab.5 Length of each algorithmic path in Task 1

单位: km

算法	UAV1路径长度	UAV2路径长度	UAV3路径长度	总平均路径长度
DQN-GWO	25.39±0.99	21.91±1.04	19.22±0.66	22.17
SCA	26.42±0.82	23.25±0.85	20.18±0.59	23.28
ACO	26.49±0.87	22.79±0.33	19.87±0.35	23.05
GWO	26.61±0.90	23.78±1.19	20.64±0.65	23.68

表 6 任务 1 中的各算法运行时间
Tab.6 Runtime of each algorithm in Task 1

单位: s

算法	UAV1运行时间	UAV2运行时间	UAV3运行时间	总平均运行时间
DQN-GWO	6.322±1.941	6.273±1.788	6.386±1.551	6.327
SCA	6.194±1.316	6.293±1.157	6.265±1.193	6.251
ACO	9.238±2.010	9.445±1.781	9.232±1.758	9.305
GWO	6.281±1.342	6.183±1.158	6.360±1.195	6.275

表 7 任务 1 中的飞行转向角
Tab.7 Flight yaw angle in Task 1

单位: (°)

算法	UAV1转向角	UAV2转向角	UAV3转向角	平均转向角
DQN-GWO	15.17±2.22	10.63±4.98	10.93±3.71	12.24
SCA	19.89±6.31	19.13±7.75	19.08±9.50	19.37
ACO	19.99±7.17	17.13±7.00	15.19±7.46	17.44
GWO	19.80±9.45	23.58±9.57	21.35±10.17	21.58

步展示了算法的稳定性: DQN-GWO 的适应度值分布区间位置最低且较为集中, 其规划路径的平均长度最短, 且波动范围较小。

在适应度方面, DQN-GWO 平均适应度为 209.06, 相比 SCA、ACO 和 GWO 分别提升 2.8%、3.6% 和 5.4%。在路径长度方面, DQN-GWO 为 22.17, 其路径长度在所有对比算法中路径最短; 在

路径平滑性方面, 其平均转向角仅为 12.24°, 显著优于 SCA(19.37°)、GWO(21.58°)和 ACO(17.44°)。在计算效率方面, DQN-GWO 平均运行时间为 6.114 s, 虽然与 SCA 和 GWO 无显著差异, 但显著优于 ACO(9.305 s)。

由此可知, 在基础场景下, DQN-GWO 在保持较好的计算效率的同时, 能生成更短、更平滑且稳




图5 任务1的多算法收敛曲线比较

Fig.5 Comparison among multi-algorithm convergence curves in Task 1

定性更高的飞行路径。

3.2 复杂场景下的多起点-多目标点路径规划任务

本节模拟3架无人机在复杂场景下, 从不同起点出发, 执行不同目标点任务(记为任务2), 重点验证算法在复杂场景下的避障机制、威胁规避一致性 & 复杂路径规划效率。在增加障碍物数量的情况下, 通过多个维度, 验证 DQN-GWO 算法在复杂协同任务中依旧有效且性能更优。该任务中的无人机

起点坐标与任务目标点坐标如表8所示。

表8 任务2初始参数设置

Tab.8 Task 2 initial parameter settings

无人机	起点	任务目标点
UAV1	(1,1,1)	(18,18,2.5)
UAV2	(2,2,1.5)	(17,17,3)
UAV3	(3,3,2)	(16,16,3.5)

该实验独立测试了30次。图7以其中一次为例, 展示 ACO、SCA、GWO 和 DQN-GWO 的路径规划结果。实验结果数据如表9~12所示。多算法收敛曲线比较图和实验结果数据箱线图见图8、9。

由图7~9和表9~12中的仿真结果可知, 在复杂场景下的多起点、多目标点路径规划任务中, DQN-GWO 仍表现出显著优势。从收敛特性看, 图8中 DQN-GWO 在迭代过程中表现出持续平滑的下降趋势, 且并未出现明显波动, 其分布范围有所






图6 任务1的实验结果数据箱线图

Fig.6 Box plots of experimental results data in Task 1



(a) ACO算法路径规划示意图(正视图)



(b) ACO算法路径规划示意图(侧视图)




图7 复杂场景下的多起点多目标点算法路径规划示意图

Fig.7 Path planning diagram of multi-start and multi-target point algorithms in complex scenarios

表9 任务2中的各算法适应度

Tab.9 Fitness of each algorithm in Task 2

算法	UAV1适应度	UAV2适应度	UAV3适应度	总平均适应度
DQN-GWO	243.93±5.80	223.91±3.78	190.89±0.24	219.58
SCA	245.96±3.27	230.10±3.60	195.84±3.34	223.97
ACO	265.54±11.54	239.24±6.43	201.32±3.07	235.37
GWO	253.58±5.94	234.71±1.91	201.32±3.95	229.87

表10 任务2中的各算法路径长度

Tab.10 Length of each algorithmic path in Task 2

单位: km

算法	UAV1路径长度	UAV2路径长度	UAV3路径长度	总平均路径长度
DQN-GWO	26.51±0.74	23.97±0.51	19.91±0.03	23.47
SCA	27.26±0.28	25.10±0.57	21.25±0.28	24.53
ACO	27.39±0.56	24.48±0.77	21.50±0.30	24.46
GWO	27.84±0.68	25.00±0.81	21.79±0.61	24.87

表 11 任务 2 中的各算法运行时间
Tab.11 Runtime of each algorithm in Task 2

单位: s

算法	UAV1运行时间	UAV2运行时间	UAV3运行时间	总平均运行时间
DQN-GWO	6.159±0.746	6.124±1.150	6.313±0.356	6.199
SCA	6.139±0.301	6.171±0.341	6.356±0.563	6.222
ACO	9.241±0.353	9.354±0.413	9.499±0.562	9.365
GWO	6.325±0.806	6.587±0.323	6.594±0.301	6.502

表 12 任务 2 中的飞行转向角
Tab.12 Flight yaw angle for Task 2

单位: (°)

算法	UAV1转向角	UAV2转向角	UAV3转向角	平均转向角
DQN-GWO	16.88±2.26	19.91±0.50	12.99±0.51	16.59
SCA	17.09±1.83	21.04±3.44	15.01±1.98	17.71
ACO	16.16±4.03	15.14±4.24	17.60±3.11	16.30
GWO	18.75±2.99	19.29±3.73	16.27±2.88	18.10

增加但仍处于最优, 说明其在复杂场景下的多起点、多目标点任务中仍具备优秀的优化稳定性。图 9 的适应度分布对比与路径长度对比显示, DQN-GWO 的适应度均值与路径长度均值均低于其他算法, 说明算法在 30 次独立测试中均能稳定输出较优的路径。




图 8 任务 2 的多算法收敛曲线比较

Fig.8 Comparison among multi-algorithm convergence curves in Task 2

在平均适应度方面, DQN-GWO 总平均适应度为 219.58, 分别较 SCA、GWO 和 ACO 提升 2.0%、4.5% 和 6.7%; 在路径长度方面, DQN-GWO 为 23.47km, 在所有算法中最短, 较 SCA、ACO 和 GWO 分别缩短 4.3%、4.1% 和 5.6%; 在路径平滑性和计算效率方面, 其平均转向角为 16.59°, 平均运行时间为 6.199 s, 在 4 种算法中均必表现最优。

通过上述两种场景的系统实验结果表明,

DQN-GWO 算法在不同场景下均能保持优良的路径规划性能和良好的收敛性能。其融合 DQN 算法优化后的决策能力与灰狼优化算法的全局搜索机制, 在适应度、路径长度和计算效率三个关键指标上均显著优于传统算法, 展现出良好的工程应用潜力。

3.3 统计显著性检验与分析

为从统计层面系统评估 DQN-GWO 算法的综合性能优势, 本文在 2 组实验场景下, 将 SCA、ACO、GWO 三种对比算法进行了配对样本 t 检验, 检验结果汇总于表 13。所有检验均以 DQN-GWO 为基准, 显著性水平设定为 $\alpha=0.05$ 。

表 13 数据显示, 在两种不同环境的测试数据中, DQN-GWO 与所有对比算法在适应度值上的差异均具有高度统计显著性(绝大多数 $p<0.001$)且所有 t 值均为负, 这表明 DQN-GWO 的适应性显著优于各对比算法。

综上所述, 统计证据一致表明: DQN 与 GWO 的融合策略有效结合了深度学习的决策能力与群体智能的优化能力。因此, 无论在简单或复杂环境中, DQN-GWO 均能稳定输出更优解, 在综合路径代价最小化问题上具有显著、可靠且适应性强的优越性。

4 总结

本文针对复杂环境下多无人机协同路径规划算




图 9 任务 2 的实验结果数据箱线图

Fig.9 Box plot of experimental results data in Task 2

表 13 与 DQN-GWO 的配对 t 检验结果

Tab.13 Paired t-test results with DQN-GWO

算法	基础场景		复杂场景	
	$t(29)$	p	$t(29)$	p
SCA	-6.143*	0.001*	-4.627*	0.000 1*
ACO	-6.975*	<0.001*	-9.085*	< 0.001*
GWO	-9.181*	< 0.001*	-9.073*	< 0.001*

注: p 为显著性概率; *表示在 $\alpha = 0.05$ 的显著性水平下, 本文算法(DQN-GWO)与对比算法的性能差异具有统计学意义

法优化问题, 在传统灰狼优化算法(GWO)的基础上, 通过算法改进融合, 构建了 DQN-GWO 混合优化框架。在 GWO 算法基础上, 本文设计了动态非线性收敛因子增强算法前期探索能力与后期精度, 引入了莱维飞行策略提升跳出局部最优的概率, 并优化了 GWO 算法的位置更新策略平衡全局搜索与局部开发效率。在此基础上, 本文结合深度 Q 网络(DQN), 构建局部决策优化模块, 提高算法适应度, 有效地解决了收敛速度慢、易陷入局部最优与适应性不足等问题。多场景的仿真实验结果表明, DQN-GWO 算法在不同任务下较传统优化算法收敛

速度更快, 适应度更优, 路径更为平滑, 最大转向角降低。实验结果验证了算法在复杂环境下规划路径的强鲁棒性与广泛适用性。尽管所提算法表现出较好的结果, 但仍有几个方向值得在未来的工作中探索。首先, 当前模型假设障碍物信息已知的假设。未来的研究中, 将结合真实场景进行实时感知的路径规划。其次, 无人机组间的协调策略可以进一步优化, 在更严格的约束下提高协作效率。最后, 计划将研究扩展至在线规划或真实平台, 从而验证其在线规划能力。总体而言, DQN-GWO 为复杂场景下的多无人机路径规划提供了一种新的解决方案。

参考文献

- [1] CHANG X C, WANG J Y, LI K, et al. Research on multi-UAV autonomous obstacle avoidance algorithm integrating improved dynamic window approach and ORCA[J/OL]. Scientific Reports, 2025, 15(1) [2025-11-20]. <https://www.nature.com/articles/s41598-025-99111-8>. DOI: 10.1038/s41598-025-99111-8.
- [2] HART P E, NILSSON N J, RAPHAEL B. A formal basis for the heuristic determination of minimum cost paths[J]. IEEE Trans-

- actions on Systems Science and Cybernetics, 1968, 4(2): 100-107.
- [3] DEB K, PRATAP A, AGARWAL S, et al. A fast and elitist multiobjective genetic algorithm: NSGA-II[J]. IEEE Transactions on Evolutionary Computation, 2002, 6(2): 182-197.
- [4] HARIS M, NAM H. Path planning optimization of smart vehicle with fast converging distance-dependent PSO algorithm[J]. IEEE Open Journal of Intelligent Transportation Systems, 2024, 5: 726-739.
- [5] JARRAY R, BOUALLÈGUE S. Improved deep Q-network-based UAV path planning in partially observable environments[J/OL]. Cluster Computing, 2025, 28: 1046 [2025-08-03]. <https://link.springer.com/article/10.1007/s10586-025-05718-x>. DOI: 10.1007/s10586-025-05718-x.
- [6] XI M, DAI H, HE J, et al. A lightweight reinforcement-learning-based real-time path-planning method for unmanned aerial vehicles[J]. IEEE Internet of Things Journal, 2024, 11(12): 21061-21071.
- [7] 杜云, 彭瑜, 邵士凯, 等. 基于改进粒子群优化的多无人机协同航迹规划[J]. 科学技术与工程, 2020, 20(32): 13258-13264.
DU Y, PENG Y, SHAO S K, et al. Multi-UAV cooperative path planning based on improved particle swarm optimization[J]. Science Technology and Engineering, 2020, 20(32): 13258-13264.
- [8] YU X, JIANG N, WANG X, et al. A hybrid algorithm based on grey wolf optimizer and differential evolution for UAV path planning[J/OL]. Expert Systems with Applications, 2023, 215 [2025-08-03] <https://www.sciencedirect.com/science/article/abs/pii/S0957417422023454>. DOI: 10.1016/j.eswa.2022.119327.
- [9] 曹建秋, 徐鹏, 张广言. 基于贪心策略下混合蚁群算法的无人机航迹规划[J]. 重庆交通大学学报(自然科学版), 2021, 40(9): 9-16,23.
CAO J Q, XU P, ZHANG G Y. UAV path planning based on hybrid ant colony algorithm with greedy strategy[J]. Journal of Chongqing Jiaotong University (Natural Science), 2021, 40(9): 9-16,23.
- [10] MEIDANI K, HEMMASIAN A P, MIRJALILI S, et al. Adaptive grey wolf optimizer[J]. Neural Computing and Applications, 2022, 34(10): 7711-7731.
- [11] ARULKUMARAN K, DEISENROTH M P, BRUNDAGE M, et al. Deep reinforcement learning: A brief survey[J]. IEEE Signal Processing Magazine, 2017, 34(6): 26-38.
- [12] 常绪成, 王敬宇, 李康, 等. 基于改进 DWA 融合算法的多无人机避障方法[J/OL]. 弹箭与制导学报 [2025-08-04]. <https://link.cnki.net/urlid/61.1234.tj.20250227.1118.002>.
CHANG X C, WANG J Y, LI K, et al. Multi-UAV obstacle avoidance method based on improved DWA fusion algorithm[J/OL]. Journal of Projectiles, Rockets, Missiles and Guidance [2025-08-04]. <https://link.cnki.net/urlid/61.1234.tj.20250227.1118.002>.
- [13] 陈超洋, 唐于特, 黄毅, 等. 面向动态障碍环境的 AUV 三维路径规划[J]. 水下无人系统学报, 2025, 33(3): 400-409.
CHEN C Y, TANG Y T, HUANG Y, et al. Three-dimensional path planning for AUV in dynamic obstacle environments[J]. Journal of Unmanned Undersea Systems, 2025, 33(3): 400-409.
- [14] LI H, LI T, SUN Y, et al. An improved grey wolf optimizer with weighting functions and its application to unmanned aerial vehicles path planning[J/OL]. Computers and Electrical Engineering, 2023, 111 [2025-08-04]. <https://www.sciencedirect.com/science/article/pii/S0045790623003178?via%3Dihub>. DOI: 10.1016/j.compeleceng.2023.108893.
- [15] WENDONG G, YU Z, JING Z, et al. A novel leader-follower-based hybrid particle swarm-grey wolf optimizer algorithm for the constrained UAV path planning[J]. Aircraft Engineering and Aerospace Technology, 2025, 97(5): 636-647.
- [16] ALOBOUD E, KURDI H. A hybrid discrete grey wolf optimizer with local search for multi-UAV Patrolling[J]. Procedia Computer Science, 2024, 241: 228-233.
- [17] XIONG H, YAO C, LIU J, et al. Improved multi-objective gray wolf optimization for task allocation in multi-UAV heterogeneous targets reconnaissance[J/OL]. Cluster Computing, 2025, 28(6) [2025-11-05]. <https://link.springer.com/article/10.1007/s10586-024-05048-4>. DOI: 10.1007/s10586-024-05048-4.
- [18] FENG J X, SUN C L, ZHANG J H, et al. A UAV path planning method in three-dimensional space based on a hybrid gray wolf optimization algorithm[J/OL]. Electronics, 2024, 13(1): 68 [2025-09-10]. <https://www.mdpi.com/2079-9292/13/1/68>. DOI: 10.3390/electronics13010068.
- [19] AHAMD H A, ZAHWE O, NASSER A, et al. Path planning for unmanned aerial vehicles in dynamic environments: A novel approach using improved A* and grey wolf optimizer[J/OL]. World Electric Vehicle Journal, 2024, 15(11) [2025-08-01]. <https://>

- /www.mdpi.com/2032-6653/15/11/531. DOI: 10.3390/wevj15110531.
- [20] HAN D, YU Q, JIANG H, et al. Three-dimensional path planning for post-disaster rescue UAV by integrating improved grey wolf optimizer and artificial potential field method[J/OL]. Applied Sciences, 2024, 14(11) [2025-08-05]. <https://www.mdpi.com/2076-3417/14/11/4461>. DOI: 10.3390/app14114461.
- [21] LV L, ZHANG S, DING D, et al. Path planning via an improved DQN-based learning policy[J]. IEEE Access, 2019, 7: 767319-67330.
- [22] YAN C, XIANG X, WANG C. Towards real-time path planning through deep reinforcement learning for a UAV in dynamic environments[J]. Journal of Intelligent & Robotic Systems, 2020, 98(2): 297-309.
- [23] LI J, SHEN D, YU F, et al. Air channel planning based on improved deep Q-learning and artificial potential fields[J/OL]. Aerospace, 2023, 10(9) [2025-11-10]. <https://www.mdpi.com/2226-4310/10/9/758>. DOI: 10.3390/aerospace10090758.
- [24] GUO Y, LIU Z. UAV path planning based on deep reinforcement learning[J]. International Journal of Advanced Network, Monitoring and Controls, 2023, 8(3): 81-88.
- [25] NAYEEM M G, FAN M, DAIYAN M G. Adaptive Q-learning grey wolf optimizer for UAV path planning[J]. Drones, 2025, 9(4) [2025-08-05]. <https://www.mdpi.com/2504-446X/9/4/246>. DOI: 10.3390/drones9040246.
- [26] CHANG X C, WANG J Y, LI K, et al. Design of UAV fusion obstacle avoidance algorithm based on DWA algorithm[C]//International Conference on Autonomous Unmanned Systems. Berlin, Germany: Springer, 2024: 521-533.

作者简介

常绪成(1983—), 男, 博士, 副教授。研究领域为多智能体协同控制。

朱 锋(2000—), 男, 硕士。研究领域为无人机路径规划。

张心慧(2002—), 女, 硕士。研究领域为无人机路径规划。